

# **El Bileđi Radyografilerinden Kemik Yaşı Tahmini İçin Derin Öğrenme Modeli: Karşılaştırmalı Deđerlendirme**

**Can Kutlay**

Doç. Dr. MURAT AYDOS

Proje Danışmanı

Hacettepe Üniversitesi

Lisansüstü Eğitim-Öğretim ve Sınav Yönetmeliğinin

Bilişim Sistemleri Anabilim Dalı

Yazılım Mühendisliği Eğitim Programı için Öngördüğü

**DÖNEM PROJESİ olarak hazırlanmıştır.**

Haziran, 2026



# **El Bileđi Radyografilerinden Kemik Yaşı Tahmini İin Derin Öğrenme Modeli: Karşılaştırmalı Deđerlendirme**

**Can Kutlay**

Do. Dr. MURAT AYDOS

Proje Danışmanı

Hacettepe Üniversitesi

Lisansüstü Eğitim-Öğretim ve Sınav Yönetmeliğinin

Bilişim Sistemleri Anabilim Dalı

Yazılım Mühendisliği Eğitim Programı için Öngördüğü

**DÖNEM PROJESİ olarak hazırlanmıştır.**

Haziran, 2026

## **KABUL VE ONAY**

Can Kutlay'nın hazırladığı "El Bileği Radyografilerinden Kemik Yaşı Tahmini İçin Derin Öğrenme Modeli: Karşılaştırmalı Değerlendirme" adlı bu çalışma Doç. Dr. MURAT AYDOS tarafından Bilişim Sistemleri Anabilim Dalı Yazılım Mühendisliği Programı'nda Dönem Projesi olarak kabul edilmiştir.

Doç. Dr. MURAT AYDOS

Proje Danışmanı

## **BİLDİRİM**

Hacettepe Üniversitesi Bilişim Enstitüsü, dönem projesi yazım kurallarına uygun olarak hazırladığım bu tez çalışmada,

- dönem projesi içindeki bütün bilgi ve belgeleri akademik kurallar çerçevesinde elde ettiğimi,
- görsel, işitsel ve yazılı tüm bilgi ve sonuçları bilimsel ahlak kurallarına uygun olarak sunduğumu,
- başkalarının eserlerinden yararlanılması durumunda ilgili eserlere bilimsel normlara uygun olarak atıfta bulunduğumu,
- atıfta bulunduğum eserlerin tümünü kaynak olarak gösterdiğimi,
- kullanılan verilerde herhangi bir tahrifat yapmadığımı,
- ve bu dönem projesinin herhangi bir bölümünü bu üniversitede veya başka bir üniversitede başka bir tez/dönem projesi çalışması olarak sunmadığımı

beyan ederim.

06/10/2026

Can Kutlay

## ÖZET

### **El Bileği Radyografilerinden Kemik Yaşı Tahmini İçin Derin Öğrenme Modeli: Karşılaştırmalı Değerlendirme**

Can Kutlay

Haziran, 2026, 20 Sayfa

Bu çalışmada, çocuklara ait el bileği X-ray görüntülerinden kemik yaşını ay cinsinden tahmin eden ve tahmin performansını yaş gruplarına göre sınıflandıran derin öğrenme tabanlı bir karar destek sistemi prototipi iki aşamada geliştirilmiştir. Kemik yaşı değerlendirmesi; büyüme geriliği, hormonal bozukluklar ve iskelet gelişim anomalilerinin tespitinde klinisyenler tarafından sıklıkla başvurulanan bir tanı yöntemidir.

Çalışmada RSNA Pediatrik Kemik Yaşı Makine Öğrenmesi Veri Seti kullanılmış olup 12.611 etiketli görüntü üzerinde beş farklı derin öğrenme mimarisi (SimpleCNN, DeepCNN, MobileNetV2, EfficientNetB0, DenseNet121) karşılaştırmalı başarımlar analizi ile değerlendirilmiştir. Tüm modeller %70/%15/%15 bölünmesiyle aynı veri seti üzerinde adil biçimde test edilmiştir.

Birinci aşamada BatchNormalization katmanları içeren DeepCNN mimarisi MAE = 17,61 ay ve  $R^2 = 0,6721$  ile en yüksek performansı sergilemiştir. İkinci aşamada cinsiyet bilgisi bağımsız bir giriş dalı aracılığıyla modele entegre edilmiş; bu yaklaşım MAE'yi 15,35 aya,  $R^2$ 'yi 0,7221'e yükseltmiştir. Sistem modüler, genişletilebilir ve tekrarlanabilir bir yazılım mimarisi üzerine inşa edilmiştir.

**Anahtar Kelimeler:** Kemik yaşı tahmini, derin öğrenme, konvolüsyonel sinir ağları, multi-input mimari, transfer öğrenmesi, BatchNormalization, RSNA, karar destek sistemi.

# İÇİNDEKİLER

|                                                 |           |
|-------------------------------------------------|-----------|
| KABUL VE ONAY .....                             | iv        |
| BİLDİRİM .....                                  | v         |
| ÖZET .....                                      | vi        |
| İÇİNDEKİLER .....                               | vii       |
| TABLolar DİZİNİ .....                           | viii      |
| ŞEKİLLER DİZİNİ .....                           | ix        |
| KISALTMALAR DİZİNİ .....                        | x         |
| <br>                                            |           |
| <b>1. BÖLÜM: GİRİŞ .....</b>                    | <b>1</b>  |
| <b>2. BÖLÜM: TEORİK ARKA PLAN .....</b>         | <b>3</b>  |
| 2.1. Kemik Yaşı ve Klinik Önemi .....           | 3         |
| 2.2. Geleneksel Değerlendirme Yöntemleri .....  | 3         |
| 2.3. Konvolüsyonel Sinir Ağları.....            | 4         |
| 2.4. Transfer Öğrenmesi.....                    | 4         |
| 2.5. Batch Normalization .....                  | 5         |
| 2.6. Multi-Input Mimariler .....                | 5         |
| <b>3. BÖLÜM: İLGİLİ ÇALIŞMALAR .....</b>        | <b>6</b>  |
| 3.1. Kemik Yaşı Tahmininde Derin Öğrenme .....  | 6         |
| 3.2. RSNA Pediatrik Kemik Yaşı Yarışması .....  | 6         |
| 3.3. Transfer Öğrenmesi Mimarileri .....        | 6         |
| 3.4. Literatür Karşılaştırması .....            | 7         |
| <b>4. BÖLÜM: YÖNTEM.....</b>                    | <b>8</b>  |
| 4.1. Veri Seti.....                             | 8         |
| 4.2. Veri Ön İşleme.....                        | 9         |
| 4.3. Model Mimarileri .....                     | 9         |
| 4.4. Multi-Input Mimari.....                    | 10        |
| 4.5. Eğitim Prosedürü .....                     | 10        |
| 4.6. Değerlendirme Metrikleri .....             | 10        |
| <b>5. BÖLÜM: DENEYSEL SONUÇLAR.....</b>         | <b>11</b> |
| 5.1. Veri Seti Analizi .....                    | 11        |
| 5.2. Aşama I — Karşılaştırmalı Başarım.....     | 12        |
| 5.3. Aşama II — Multi-Input Model .....         | 13        |
| 5.4. Genel Karşılaştırma (6 Model).....         | 13        |
| 5.5. Confusion Matrix Analizi .....             | 14        |
| <b>6. BÖLÜM: YAZILIM SİSTEMİ TASARIMI .....</b> | <b>16</b> |
| 6.1. Sistem Mimarisi .....                      | 16        |
| 6.2. Bileşen Açıklamaları .....                 | 16        |

|                               |           |
|-------------------------------|-----------|
| 6.3. Veri Akışı .....         | 16        |
| <b>7. BÖLÜM: SONUÇ .....</b>  | <b>18</b> |
| 7.1. Temel Bulgular .....     | 18        |
| 7.2. Sınırlılıklar .....      | 18        |
| 7.3. Gelecek Çalışmalar ..... | 18        |
| <b>KAYNAKÇA .....</b>         | <b>19</b> |

## TABLOLAR DİZİNİ

|                                                                                  |    |
|----------------------------------------------------------------------------------|----|
| Tablo 2.1 — Kemik yaşı değerlendirme yöntemlerinin karşılaştırması .....         | 4  |
| Tablo 3.1 — Literatürdeki kemik yaşı tahmin çalışmalarının karşılaştırması ..... | 7  |
| Tablo 4.1 — Veri seti temel istatistikleri.....                                  | 8  |
| Tablo 4.2 — Train/Validation/Test bölünme istatistikleri .....                   | 9  |
| Tablo 4.3 — Model mimarilerinin karşılaştırmalı özeti .....                      | 9  |
| Tablo 5.1 — Aşama I karşılaştırmalı başarımlar analizi — 5 model .....           | 12 |
| Tablo 5.2 — Tek girişli ve multi-input DeepCNN karşılaştırması .....             | 13 |
| Tablo 5.3 — 6 modelin final karşılaştırması.....                                 | 13 |
| Tablo 5.4 — DeepCNN_MultiInput yaş grubu confusion matrix .....                  | 14 |
| Tablo 6.1 — Sistem bileşenleri ve kullanılan teknolojiler .....                  | 16 |



## ŞEKİLLER DİZİNİ

|                                                                                     |    |
|-------------------------------------------------------------------------------------|----|
| Şekil 4.1 — RSNA veri setinden rastgele seçilmiş el bileği X-ray örnekleri .....    | 8  |
| Şekil 5.1 — Kemik yaşı dağılımı, cinsiyet dağılımı ve cinsiyete göre kemik yaşı. 11 |    |
| Şekil 5.2 — Yaş gruplarına göre örnek dağılımı .....                                | 11 |
| Şekil 5.3 — 5 model karşılaştırmalı başarımlar analizi (MAE, RMSE, $R^2$ ) .....    | 12 |
| Şekil 5.4 — DeepCNN — gerçek vs tahmin scatter plot ve hata dağılımı .....          | 12 |
| Şekil 5.5 — DeepCNN Multi-Input — eğitim kaybı, scatter ve hata dağılımı .....      | 13 |
| Şekil 5.6 — 6 model final benchmark karşılaştırması .....                           | 14 |
| Şekil 5.7 — DeepCNN Multi-Input detaylı confusion matrix.....                       | 14 |

## KISALTMALAR DİZİNİ

|       |   |                                                        |
|-------|---|--------------------------------------------------------|
| TL    | — | Transfer Learning (Transfer Öğrenmesi)                 |
| RSNA  | — | Radiological Society of North America                  |
| RMSE  | — | Karekök Ortalama Kare Hata (Root Mean Squared Error)   |
| RGB   | — | Red Green Blue                                         |
| REST  | — | Representational State Transfer                        |
| $R^2$ | — | Belirleme Katsayısı (Coefficient of Determination)     |
| PNG   | — | Portable Network Graphics                              |
| MSE   | — | Ortalama Kare Hata (Mean Squared Error)                |
| MAE   | — | Ortalama Mutlak Hata (Mean Absolute Error)             |
| GPU   | — | Grafik İşlem Birimi                                    |
| GAP   | — | Global Average Pooling                                 |
| CSV   | — | Comma-Separated Values                                 |
| CNN   | — | Konvolüsyonel Sinir Ağı (Convolutional Neural Network) |
| BN    | — | Batch Normalization                                    |
| API   | — | Application Programming Interface                      |

## 1. BÖLÜM: GİRİŞ

İnsan iskelet sisteminin gelişimi, bir bireyin biyolojik olgunluğunu en doğru biçimde yansıtan göstergelerden biridir. Kemik yaşı, iskelet gelişim düzeyini sayısal olarak ifade eden ve kronolojik yaştan bağımsız olarak değerlendirilebilen bir biyolojik parametre olarak tanımlanmaktadır. Kemik yaşı değerlendirmesi; büyüme geriliği, erken veya geç ergenlik, hipotiroidi, büyüme hormonu eksikliği ve çeşitli endokrin bozuklukların tanı ve tedavi süreçlerinde klinisyenler tarafından yaygın biçimde kullanılmaktadır. Bunların yanı sıra adli tıp alanında yaşı belgelenmemiş bireylerin kronolojik yaşının belirlenmesinde de kritik bir araç işlevi görmektedir [1].

Geleneksel kemik yaşı değerlendirmesinde en yaygın kullanılan yöntem Greulich-Pyle atlasıdır [1]. Bu yöntemde radyolog, el bileği X-ray görüntüsünü atladaki referans görüntülerle karşılaştırarak kemik yaşını tahmin eder. Tanner-Whitehouse yöntemi ise el bilek kemiklerinin her birini ayrı ayrı puanlayarak daha sistematik bir değerlendirme sunar [19]. Her iki yöntem de deneyimli bir radyolog gerektirmekte, gözlemciler arası tutarsızlıklara yol açabilmekte ve yüksek hasta hacimli kliniklerde önemli zaman kayıplarına neden olmaktadır.

Derin öğrenme yöntemlerinin tıbbi görüntü işleme alanında elde ettiği çarpıcı başarılar, kemik yaşı tahmininin otomasyonunu mümkün kılan araştırmaları hızlandırmıştır. Konvolüsyonel Sinir Ağları (CNN) [12], görüntüden hiyerarşik özellik çıkarabilme yetenekleri sayesinde radyoloji, patoloji ve dermatoloji alanlarında uzman performansına yaklaşan sonuçlar üretmeye başlamıştır. 2017 yılında RSNA tarafından düzenlenen Pediatrik Kemik Yaşı Makine Öğrenmesi Yarışması [2], 250'den fazla katılımcı takımın geliştirdiği modellerle medyan MAE değeri 5,99 ay olarak gerçekleşmiştir.

Bu proje iki temel aşamada yürütülmüştür. Birinci aşamada beş farklı derin öğrenme mimarisi karşılaştırmalı başarımların analizi ile değerlendirilmiştir. İkinci aşamada ise en başarılı mimari cinsiyet bilgisiyle zenginleştirilerek çok girişli (multi-input) bir modele dönüştürülmüş ve başarımların iyileştirilmesi sağlanmıştır.

Projenin temel hedefleri şöyle özetlenebilir:

- El bileği X-ray görüntülerinden kemik yaşını ay cinsinden tahmin etmek,
- Farklı derin öğrenme mimarilerini adil bir başarımların analizi çerçevesinde karşılaştırmak,

- Cinsiyet bilgisini modele entegre ederek tahmin başarımını artırmak,
- Tahmin sonuçlarını yaş gruplarına göre sınıflandırarak yorumlanabilir çıktı üretmek,
- Yazılım Mühendisliği ilkeleriyle modüler ve tekrarlanabilir bir sistem tasarlamak.

Bu raporun yapısı şu şekilde düzenlenmiştir: İkinci bölümde teorik arka plan aktarılmakta, üçüncü bölümde ilgili çalışmalar özetlenmekte, dördüncü bölümde yöntem detaylandırılmakta, beşinci bölümde deneysel sonuçlar sunulmakta, altıncı bölümde yazılım sistemi tasarımı açıklanmakta ve yedinci bölümde sonuç ile gelecek çalışmalar tartışılmaktadır.

## 2. BÖLÜM: TEORİK ARKA PLAN

### 2.1. Kemik Yaşı ve Klinik Önemi

Kemik yaşı, el bileği ve el kemiklerinin radyografik görüntüsünden değerlendirilen ve iskelet sisteminin biyolojik olgunluk düzeyini ifade eden bir ölçüttür. Kemiklerin şekillenmesi, büyüme plaklarının kapanması ve kemik yoğunluğundaki değişimler kronolojik yaştan bağımsız olarak değerlendirilebilen iskelet gelişim göstergeleri arasında yer almaktadır.

Kemik yaşı değerlendirmesinin klinik kullanım alanları şunlardır:

- Büyüme geriliği tanısı: Kemik yaşının kronolojik yaştan gerisinde kalması büyüme hormonu eksikliğine işaret edebilir.
- Erken ve geç ergenlik: Kemik yaşının kronolojik yaştan belirgin ilerisinde olması erken ergenlik bulgusunu destekler.
- Adli tıp: Yaşı belgesiz bireylerin kronolojik yaş aralığının belirlenmesinde kritik referans sağlar.
- Spor hekimliği: Atletlerin gelişim düzeyinin belirlenmesinde kullanılır.
- Ortodonti ve ortopedi: Büyüme döneminin sonuna yaklaşıldığının tespiti cerrahi müdahale zamanlamasını etkiler.

### 2.2. Geleneksel Kemik Yaşı Değerlendirme Yöntemleri

#### 2.2.1. Greulich-Pyle Yöntemi

Greulich ve Pyle tarafından geliştirilen bu yöntem [1], el-el bileği X-ray görüntüsünün referans atlasla karşılaştırılmasına dayanmaktadır. Atlas 0–19 yaş aralığında cinsiyete göre ayrılmış standart görüntüler içermektedir. Yöntem basit ve hızlıdır; ancak subjektif değerlendirme ve atlasın 1900'lü yıllarda hazırlanmış olması nedeniyle sınırlılıklar taşımaktadır.

#### 2.2.2. Tanner-Whitehouse Yöntemi

Tanner ve Whitehouse tarafından geliştirilen TW yöntemi [19], el-el bileği kemiklerinin her birini ayrı ayrı puanlayarak toplam skor üzerinden kemik yaşını hesaplamaktadır. GP yöntemine kıyasla daha sistematik ancak daha zaman alıcıdır.

Tablo 2.1'de bu iki yöntemin derin öğrenme yaklaşımıyla karşılaştırması sunulmaktadır.

| Özellik           | Greulich-Pyle       | Tanner-Whitehouse | Derin Öğrenme (Bu Çalışma) |
|-------------------|---------------------|-------------------|----------------------------|
| Değerlendirme     | Atlas karşılaştırma | Kemik puanlama    | Otomatik tahmin            |
| Uygulama süresi   | 2–5 dakika          | 10–15 dakika      | < 1 saniye                 |
| Uzman bağımlılığı | Yüksek              | Yüksek            | Yok                        |
| Gözlemciler arası | Orta                | İyi               | Yüksek (deterministik)     |
| Ölçeklenebilirlik | Düşük               | Düşük             | Yüksek                     |

Tablo 2.1 — Kemik yaşı değerlendirme yöntemlerinin karşılaştırması.

### 2.3. Konvolüsyonel Sinir Ağları

Konvolüsyonel Sinir Ağları (CNN), görüntü verisi üzerinde hiyerarşik özellik çıkarımı yapabilen özel bir derin öğrenme mimarisidir. LeCun ve arkadaşları [12] tarafından temelleri atılan bu mimari, Krizhevsky ve arkadaşlarının 2012 yılında ImageNet yarışmasında elde ettiği çarpıcı sonuçlardan [13] sonra baskın görüntü işleme yöntemi haline gelmiştir.

#### 2.3.1. Temel Bileşenler

- Konvolüsyon Katmanı: Öğrenilebilir filtreler görüntü üzerinde kaydırılarak kenarlar, dokular ve şekiller gibi yerel özellikler çıkarılır.
- Aktivasyon Fonksiyonu (ReLU):  $f(x) = \max(0, x)$  ile lineer olmayan dönüşüm sağlar. Gradyan kaybını azaltması nedeniyle günümüz ağlarında standarttır.
- MaxPooling: Özellik haritasının boyutunu küçülterek öteleme değişmezliği sağlar.
- Global Average Pooling (GAP): Her özellik haritasının ortalamasını alarak parametre sayısını azaltır, aşırı öğrenmeye karşı daha dirençlidir.
- Dropout: Eğitim sırasında nöronları rastgele devre dışı bırakarak aşırı öğrenmeyi önler. Bu çalışmada 0,3 ve 0,4 oranları kullanılmıştır.

### 2.4. Transfer Öğrenmesi

Transfer öğrenmesi, büyük ölçekli bir veri seti üzerinde önceden eğitilmiş bir modelin ağırlıklarının farklı ancak ilişkili bir görev için yeniden kullanılması yaklaşımıdır. Pan ve Yang [16], transfer öğrenmesini kaynak alan ile hedef alan arasındaki bilgi aktarımı olarak tanımlamıştır. ImageNet üzerinde eğitilen modeller, genel görsel özellikleri kodlayarak medikal görüntüleme görevlerine transfer edilebilmektedir.

Bu projede transfer öğrenmesi modelleri ImageNet ağırlıkları dondurulmuş hâlde uygulanmıştır. Fine-tuning yapılmaması GPU kısıtlı ortamda hesaplama verimliliği sağlamış; ancak medikal görüntülere uyum kapasitesini sınırlandırmıştır.

## **2.5. Batch Normalization**

Ioffe ve Szegedy [9] tarafından önerilen Batch Normalization, her mini-batch için ara katman çıktıları normalize ederek iç kovaryan kaymasını azaltmaktadır. Temel katkıları şunlardır: daha yüksek öğrenme hızı kullanımına olanak tanır, dropout'a ek düzenleme sağlar ve vanishing/exploding gradient sorunlarını hafifletir. Bu projede Batch Normalization, DeepCNN'in transfer öğrenmesi modellerini geride bırakmasına katkıda bulunan merkezi bileşen olarak değerlendirilmektedir.

## **2.6. Multi-Input Derin Öğrenme Mimarileri**

Çok girişli mimarilerde her girdi kaynağı için bağımsız bir dal tanımlanmakta; dalların çıktıları Concatenate veya Add katmanlarında ortak temsile dönüştürülmektedir. Kemik yaşı tahmininde multi-input motivasyonu şudur: kız çocuklarında iskelet olgunlaşması erkeklere kıyasla ortalama 1–2 yıl daha erken gerçekleşmektedir. Cinsiyet bilgisinin görüntü özellikleriyle birleştirilmesi bu biyolojik farkın doğrudan modellenmesini sağlamaktadır.

### **3. BÖLÜM: İLGİLİ ÇALIŞMALAR**

#### **3.1. Kemik Yaşı Tahmininde Derin Öğrenme**

Larson ve arkadaşları [8], 2018 yılında derin öğrenme tabanlı bir modelin el radyografilerinde iskelet olgunluğunu değerlendirmede radyolog düzeyinde performans sergileyebildiğini göstermiştir. 14.036 görüntü üzerinde eğitilen model, ortalama 0,61 yıllık hatayla deneyimli radyologların 0,63 yıllık hatasını geçerek klinik kullanım potansiyelini ortaya koymuştur.

Tajmir ve arkadaşları [17], Boston Çocuk Hastanesi'nden elde edilen 9.266 görüntüyle geliştirdikleri modelde MAE = 0,87 yıl elde etmiştir. Lee ve arkadaşları [18], tamamen otomatik uçtan uca bir derin öğrenme sistemi geliştirerek klinik iş akışına entegrasyon için prototip oluşturmuştur.

#### **3.2. RSNA Pediatrik Kemik Yaşı Yarışması**

2017 yılında RSNA tarafından düzenlenen yarışma [2], Stanford Üniversitesi ve Colorado Çocuk Hastanesi iş birliğiyle hazırlanmış 12.611 etiketli görüntüyü kapsamaktadır. 250'den fazla takım katılmış; MAE değerleri 4,27 ile 34,16 ay arasında değişmiş ve medyan MAE 5,99 ay olarak gerçekleşmiştir [3]. Her görüntü için etiket en az iki radyologun konsensüsüyle belirlenmiştir.

#### **3.3. Transfer Öğrenmesi Mimarileri**

He ve arkadaşları [14] tarafından geliştirilen ResNet, artık bağlantılar sayesinde 100 katmanı aşan derin ağların eğitimini mümkün kılmıştır. Simonyan ve Zisserman [15] tarafından geliştirilen VGGNet, 3×3 küçük filtrelerden oluşan derin yığıntılarla yüksek temsil gücü sunmaktadır. Sandler ve arkadaşları [5] tarafından geliştirilen MobileNetV2, ters artık yapılarla mobil sistemler için optimize edilmiş hafif bir mimaridir. Tan ve Le [6] tarafından önerilen EfficientNet, bileşik ölçekleme yöntemiyle parametre verimliliğinde yeni bir standart oluşturmuştur. DenseNet121 [7] ise yoğun bağlantı yapısıyla özellik yeniden kullanımını maksimize etmektedir.



### 3.4. Literatür Karşılaştırması

Tablo 3.1'de bu projenin ilgili çalışmalarla kıyası sunulmaktadır.

| Çalışma                  | Veri Seti      | Yöntem                  | MAE      | Yıl  |
|--------------------------|----------------|-------------------------|----------|------|
| Larson ve ark.<br>[8]    | 14.036 görüntü | Özel CNN                | 0,61 yıl | 2018 |
| Tajmir ve ark.<br>[17]   | 9.266 görüntü  | CNN                     | 0,87 yıl | 2019 |
| RSNA Medyan<br>[3]       | 12.611 görüntü | Çeşitli                 | 5,99 ay  | 2019 |
| Bu Çalışma —<br>Aşama I  | 12.611 görüntü | DeepCNN                 | 17,61 ay | 2026 |
| Bu Çalışma —<br>Aşama II | 12.611 görüntü | DeepCNN Multi-<br>Input | 15,35 ay | 2026 |

Tablo 3.1 — Literatürdeki temel kemik yaşı tahmin çalışmalarının karşılaştırması.

## 4. BÖLÜM: YÖNTEM


### 4.1. Veri Seti

Bu çalışmada RSNA Pediatrik Kemik Yaşı Makine Öğrenmesi Yarışması'nın eğitim veri seti kullanılmıştır [4]. Veri seti Stanford Üniversitesi Tıp Fakültesi ve Colorado Çocuk Hastanesi radyoloji arşivlerinden derlenerek Kaggle platformu üzerinden kamuya açık hale getirilmiştir. Her görüntü için kemik yaşı etiketi en az iki deneyimli radyolog tarafından konsensüs ile belirlenmiştir. Tablo 4.1'de veri setinin temel istatistikleri sunulmaktadır.

| Özellik             | Değer    | Özellik           | Değer                 |
|---------------------|----------|-------------------|-----------------------|
| Toplam görüntü      | 12.611   | Medyan kemik yaşı | 132 ay                |
| Ortalama kemik yaşı | 127,3 ay | Erkek / Kız       | %54,2 / %45,8         |
| Standart sapma      | 41,2 ay  | Yaş aralığı       | 1–228 ay              |
| Veri formatı        | PNG      | Etiketleme        | ≥2 radyolog konsensüs |

Tablo 4.1 — Veri seti temel istatistikleri.

Şekil 4.1'de veri setinden rastgele seçilmiş görüntü örnekleri sunulmaktadır.



Şekil 4.1 — RSNA veri setinden rastgele seçilmiş el bileği X-ray örnekleri. Yaş arttıkça karpal kemiklerin büyüdüğü ve kemik yoğunluğunun arttığı izlenmektedir.

## 4.2. Veri Ön İşleme

### 4.2.1. Veri Temizleme

12.611 kaydın tamamında görüntü eşleşmesi doğrulanmıştır. Eksik değer, yinelenen kayıt ve bozuk görüntü tespit edilmemiştir.

### 4.2.2. Görüntü Boyutlandırma ve Normalizasyon

Görüntüler 128×128 piksel boyutuna bilinear interpolasyon ile yeniden ölçeklendirilmiştir. Normalizasyon için görüntü başına maksimum piksel değerine bölme yöntemi uygulanmıştır. Bu yaklaşım veri setinin içerebileceği farklı piksel derinliklerinden bağımsız tutarlı sonuçlar üretmektedir.

### 4.2.3. Kanal Dönüşümü ve Veri Artırma

Gri tonlamalı görüntüler 3 kanallı (RGB) formata dönüştürülmüştür. Yalnızca eğitim setine yatay çevirme (RandomFlip),  $\pm 5^\circ$  döndürme (RandomRotation) ve  $\pm 10\%$  yakınlaştırma (RandomZoom) uygulanmıştır.

### 4.2.4. TensorFlow Dataset Pipeline.

Ön işleme TensorFlow tf.data API'si ile gerçekleştirilmiştir [11].

- cache(): İlk epoch'ta görüntüler RAM'de ön belleğe alınır.
- batch(64): 64 görüntülük mini-batch'ler oluşturulur.
- prefetch(AUTOTUNE): Bir sonraki batch mevcut işlenirken hazırlanır.

Veri bölünmesi %70/%15/%15 oranlarında random\_state=42 ile stratified split kullanılarak gerçekleştirilmiştir. Tablo 4.2'de sonuçlar verilmektedir.

| Bölüm     | Kayıt | Ort. Kemik Yaşı (ay) | Std. | Erkek % |
|-----------|-------|----------------------|------|---------|
| Eğitim    | 8.827 | 127,4                | 41,2 | %54,2   |
| Doğrulama | 1.892 | 127,4                | 40,9 | %53,7   |
| Test      | 1.892 | 127,0                | 41,3 | %54,7   |

Tablo 4.2 — Train/Validation/Test bölünme istatistikleri.

## 4.3. Model Mimarileri

| Model              | Tip        | Parametre | Özellik            | Önceki Eğitim   |
|--------------------|------------|-----------|--------------------|-----------------|
| SimpleCNN          | Özel CNN   | 109.889   | 3 konv blok        | Yok             |
| DeepCNN            | Özel CNN   | 666.401   | 4 konv blok + BN   | Yok             |
| MobileNetV2        | Transfer   | 2.602.433 | Ters artık         | ImageNet frozen |
| EfficientNetB0     | Transfer   | 4.394.020 | Bileşik ölçekleme  | ImageNet frozen |
| DenseNet121        | Transfer   | 7.316.417 | Yoğun bağlantı     | ImageNet frozen |
| DeepCNN MultiInput | Özel Multi | 693.185   | 4 konv+BN+cinsiyet | Yok             |

Tablo 4.3 — Model mimarilerinin karşılaştırmalı özeti.

#### **4.3.1. SimpleCNN**

Üç konvolüsyon bloğundan (32/64/128 filtre) oluşan temel mimaridir. Her blok Conv2D + MaxPooling içermekte; son olarak GAP, Dense(128, ReLU), Dropout(0.3) ve tek nöronlu doğrusal çıktı gelmektedir. 109.889 parametre içermektedir.

#### **4.3.2. DeepCNN**

Her biri BatchNormalization [9] içeren dört konvolüsyon bloğu (32/64/128/256 filtre) ve iki tam bağlı katmandan oluşmaktadır. 666.401 parametre içermektedir.

#### **4.3.3. Transfer Öğrenmesi Modelleri**

MobileNetV2, EfficientNetB0 ve DenseNet121 için ortak üst yapı: GAP → Dense(256, ReLU) → Dropout(0.3) → Dense(64, ReLU) → Dense(1, linear). Tüm backbone ağırlıkları frozen tutulmuştur.

#### **4.4. Multi-Input Mimari**

Görüntü dalı orijinal DeepCNN backbone'unu içererek 256 boyutlu özellik vektörü üretmekte; cinsiyet dalı tek sayısal değeri (0/1) Dense(16, ReLU)'dan geçirmektedir. İki dalın çıktısı Concatenate katmanında birleştirilerek Dropout(0.4), Dense(128, ReLU), Dense(64, ReLU) ve tek nöronlu doğrusal çıktıya iletilmektedir. Toplam 693.185 parametre içermektedir.

#### **4.5. Eğitim Prosedürü**

Tüm modeller Adam optimize edici [10] (öğrenme hızı: 0,001) ve MAE kayıp fonksiyonu ile eğitilmiştir. Maksimum 25 epoch; EarlyStopping (patience=5), ReduceLROnPlateau (patience=3, factor=0.5) ve ModelCheckpoint callback'leri ile yönetilmiştir. Her model tamamlandığında ara kayıt mekanizması ile sonuçlar CSV dosyasına yazılmıştır.

#### **4.6. Değerlendirme Metrikleri**


- MAE: Tahmin hatalarının mutlak ortalaması. Ay cinsinden yorumlanabilir.
- MSE: Büyük hataları orantısız cezalandırır.
- RMSE: MSE'nin karekökü; MAE ile aynı birimler.
- R<sup>2</sup>: Modelin varyansı açıklama oranı. 1,0 = mükemmel; negatif = ortalamanın altında.

Sınıflandırma değerlendirmesi için tahminler üç gruba ayrılmıştır: Küçük (0–84 ay), Orta (85–144 ay), Büyük (145+ ay).

## 5. BÖLÜM: DENEYSEL SONUÇLAR


### 5.1. Veri Seti Analizi

12.611 kaydın tamamında görüntü eşleşmesi doğrulanmış; normalizasyon sonrasında piksel değerleri [0, 1] aralığına getirilmiştir. Şekil 5.1 ve Şekil 5.2 veri setinin istatistiksel dağılımını sunmaktadır.



Şekil 5.1 — Kemik yaşı dağılımı (ortalama: 127 ay, medyan: 132 ay), cinsiyet dağılımı (%54,2 erkek) ve cinsiyete göre kemik yaşı dağılımı.

Kemik yaşı dağılımı hafif sol çarpıklık sergilemektedir (ortalama < medyan). 11–14 yaş grubu toplam verinin %39,7'sini oluştururken 0–2 yaş grubu yalnızca 91 örnekle temsil edilmektedir.




Şekil 5.2 — Yaş gruplarına göre örnek dağılımı. 0–2 yaş grubundaki yetersiz temsil bu gruptaki tahmin başarımını olumsuz etkilemektedir.

## 5.2. Aşama I — Karşılaştırmalı Başarım Analizi (5 Model)

Beş model aynı veri bölünmesiyle değerlendirilmiştir.


| Model          | MAE (ay) | MSE      | RMSE (ay) | R <sup>2</sup> | Süre (sn) | Parametre |
|----------------|----------|----------|-----------|----------------|-----------|-----------|
| DeepCNN        | 17,61    | 561,60   | 23,67     | 0,6721         | 2.070     | 666.401   |
| DenseNet121    | 22,05    | 785,68   | 28,03     | 0,5401         | 1.243     | 7.316.417 |
| MobileNetV2    | 25,13    | 1.018,88 | 31,92     | 0,4036         | 213       | 2.602.433 |
| EfficientNetB0 | 33,34    | 1.801,82 | 42,45     | -0,0550        | 144       | 4.394.020 |
| SimpleCNN      | 33,60    | 1.788,29 | 42,29     | -0,0468        | 121       | 109.889   |

Tablo 5.1 — Aşama I karşılaştırmalı başarım analizi. Yeşil satır en iyi modeli göstermektedir.



Şekil 5.3 — 5 model karşılaştırmalı başarım analizi: MAE, RMSE ve R<sup>2</sup> metrikleri. DeepCNN tüm metriklerde üstün performans sergilemiştir.

BatchNormalization içeren DeepCNN, dondurulmuş ImageNet ağırlıklı tüm transfer öğrenmesi modellerini geride bırakmıştır. EfficientNetB0 ve SimpleCNN'in negatif R<sup>2</sup> değerleri bu modellerin ortalama tahminden bile düşük performans sergilediğini ortaya koymaktadır.




Şekil 5.4 — DeepCNN: gerçek vs tahmin scatter plot (sol) ve hata dağılımı (sağ). Ortalama hata 8,4 ay olup dağılım yaklaşık normaldir.

### 5.3. Aşama II — Multi-Input Model

Cinsiyet bilgisinin entegrasyonundan elde edilen sonuçlar Tablo 5.2 ve Şekil 5.5'te sunulmaktadır.

| Model              | MAE (ay) | RMSE (ay) | R <sup>2</sup> | Süre (sn) | Parametre |
|--------------------|----------|-----------|----------------|-----------|-----------|
| DeepCNN            | 17,61    | 23,67     | 0,6721         | 2.070     | 666.401   |
| DeepCNN_MultiInput | 15,35    | 21,79     | 0,7221         | 1.529     | 693.185   |
| İyileşme           | -2,26 ay | -1,88 ay  | +0,0500        | -541 sn   | +26.784   |

Tablo 5.2 — Tek girişli ve multi-input DeepCNN karşılaştırması.




Şekil 5.5 — DeepCNN Multi-Input: eğitim/doğrulama kaybı (sol), scatter plot (orta, MAE=15,35 ay, R<sup>2</sup>=0,7221) ve hata dağılımı (sağ).

Cinsiyet bilgisinin entegrasyonu MAE'yi %12,8 azaltmış, R<sup>2</sup>'yi %5 artırmıştır. Eğitim süresinin 541 saniye kısalması modelin daha hızlı yakınsamasına işaret etmektedir.

### 5.4. Genel Karşılaştırma (6 Model)

| Sıra | Model              | MAE (ay) | RMSE (ay) | R <sup>2</sup> |
|------|--------------------|----------|-----------|----------------|
| 1    | DeepCNN_MultiInput | 15,35    | 21,79     | 0,7221         |
| 2    | DeepCNN            | 17,61    | 23,67     | 0,6721         |
| 3    | DenseNet121        | 22,05    | 28,03     | 0,5401         |
| 4    | MobileNetV2        | 25,13    | 31,92     | 0,4036         |
| 5    | EfficientNetB0     | 33,34    | 42,45     | -0,0550        |
| 6    | SimpleCNN          | 33,60    | 42,29     | -0,0468        |

Tablo 5.3 — 6 modelin final karşılaştırması.




Şekil 5.6 — 6 model final benchmark karşılaştırması. DeepCNN\_MultiInput hem MAE hem  $R^2$  metriklerinde lider konumundadır.

### 5.5. Confusion Matrix Analizi

Kemik yaşı tahminleri Küçük (0–84 ay), Orta (85–144 ay) ve Büyük (145+ ay) gruplarına ayrılarak sınıflandırma başarımları değerlendirilmiştir.

| Gerçek \ Tahmin | Küçük (0–7 yaş) | Orta (7–12 yaş) | Büyük (12+ yaş) |
|-----------------|-----------------|-----------------|-----------------|
| Küçük (0–7 yaş) | 154             | 195             | 5               |
| Orta (7–12 yaş) | 5               | 643             | 177             |
| Büyük (12+ yaş) | 0               | 106             | 607             |

Tablo 5.4 — DeepCNN\_MultiInput yaş grubu confusion matrix (test seti,  $n=1.892$ ).



Şekil 5.7 — DeepCNN Multi-Input detaylı confusion matrix. Köşegen değerler (154, 643, 607) doğru sınıflandırmaları göstermektedir.



1.892 örnekten 1.404'ü (%74,2) doğru yaş grubuna atanmıştır. Büyük grupta  $607/713 = \%85,1$  doğruluk elde edilirken Küçük grupta  $154/354 = \%43,5$  ile düşük başarımlar gözlemlenmiştir. Bu durum örneklem dengesizliğiyle ilişkilidir.

## 6. BÖLÜM: YAZILIM SİSTEMİ TASARIMI

### 6.1. Sistem Mimarisi

Bu proje veri işleme, model eğitimi, değerlendirme ve raporlama bileşenlerini kapsayan beş katmanlı yazılım mimarisi üzerine inşa edilmiştir:

- Veri Katmanı: CSV okuma, görüntü yolu eşleştirme ve doğrulama.
- Ön İşleme Katmanı: TensorFlow Dataset API ile yükleme, normalizasyon, artırma, cache.
- Model Katmanı: Keras Functional API ile CNN ve multi-input mimariler. MODEL\_REGISTRY yapısı yeni modellerin kolayca eklenmesini sağlar.
- Değerlendirme Katmanı: scikit-learn ile MAE, MSE, RMSE,  $R^2$  ve confusion matrix.
- Raporlama Katmanı: matplotlib/seaborn ile görselleştirme; pandas ile CSV çıktısı.

Sistem güvenilirliği için sabit random\_state=42 ve ara kayıt mekanizması kullanılmıştır.

### 6.2. Bileşen Açıklamaları

| Bileşen           | Teknoloji            | Görev                                    |
|-------------------|----------------------|------------------------------------------|
| Veri Yükleme      | pandas, pathlib      | CSV okuma, görüntü eşleştirme            |
| Görüntü Doğrulama | Pillow (PIL)         | Bozuk görüntü tespiti                    |
| Dataset Pipeline  | TensorFlow tf.data   | Yükleme, cache, batch, prefetch          |
| Görüntü Artırma   | Keras preprocessing  | RandomFlip, Rotation, Zoom               |
| Model Tanımlama   | Keras Functional API | CNN ve multi-input mimariler             |
| Transfer Backbone | Keras Applications   | MobileNetV2, EfficientNetB0, DenseNet121 |
| Model Eğitimi     | TensorFlow           | fit, EarlyStopping, ReduceLR, Checkpoint |
| Metrik Hesaplama  | scikit-learn         | MAE, MSE, RMSE, $R^2$ , confusion matrix |
| Görselleştirme    | matplotlib, seaborn  | Grafik, scatter, heatmap                 |
| Raporlama         | pandas               | CSV çıktı, benchmark tablosu             |
| Geliştirme Ortamı | Jupyter Notebook     | Etkileşimli kod ve görsel                |

Tablo 6.1 — Sistem bileşenleri ve kullanılan teknolojiler.

### 6.3. Veri Akışı

Sistemin uçtan uca akışı şu adımlarla özetlenebilir:

- Giriş: X-ray görüntüsü (PNG) + cinsiyet bilgisi (0/1)
- Ön İşleme: Resize (128×128) → normalize [0,1] → 3 kanal
- Tahmin: DeepCNN\_MultiInput → kemik yaşı (ay)

- Sapma:  $\text{sapma} = \text{tahmin} - \text{gerçek}$ ;  $\text{yüzde\_sapma} = \text{sapma} / \text{gerçek} \times 100$
- Çıktı: Tahmin, sapma, yüzde sapma, yaş grubu

Bu mimari Flask/FastAPI tabanlı web arayüzü veya hastane bilgi sistemlerine entegrasyon için temel oluşturmaktadır.

## 7. BÖLÜM: SONUÇ

### 7.1. Temel Bulgular

Bu çalışmada el bileği X-ray görüntülerinden kemik yaşını tahmin eden derin öğrenme tabanlı bir karar destek sistemi prototipi iki aşamada geliştirilmiştir.

- DeepCNN (MAE=17,61 ay,  $R^2=0,6721$ ), dondurulmuş ImageNet ağırlıklı tüm transfer öğrenmesi modellerini geride bırakmıştır. BatchNormalization bu başarının temel belirleyicisi olarak değerlendirilmektedir.
- Cinsiyet bilgisinin entegrasyonu (DeepCNN\_MultiInput) MAE'yi %12,8 azaltmış,  $R^2$ 'yi 0,7221'e yükseltmiştir. Demografik bilgilerin görüntü tabanlı modellere katkısı kanıtlanmıştır.
- Yaş grubu sınıflandırmasında %74,2 doğruluk elde edilmiştir.
- Stratified split, ara kayıt mekanizması ve MODEL\_REGISTRY yapısı sistemin mühendislik kalitesini artırmaktadır.

### 7.2. Sınırlılıklar

- Hesaplama altyapısı: Tüm eğitimler CPU'da gerçekleşmiştir; fine-tuning uygulanamamıştır.
- Dondurulmuş transfer: ImageNet ağırlıklarının medikal görüntülere uyumsuzluğu performans açığının temel kaynağıdır.
- Veri dengesizliği: 0–2 yaş grubunun az temsili sınıflandırma başarımını olumsuz etkilemiştir.
- Klinik doğrulama eksikliği: Sistem gerçek hasta verisi üzerinde test edilmemiştir.

### 7.3. Gelecek Çalışmalar

- GPU ile fine-tuning: Son katmanların açılması  $R^2$ 'yi 0,85 üzerine çıkarabilir.
- Yüksek çözünürlük: 224×224 ile daha ince kemik yapılarının öğrenilmesi.
- Ensemble: DeepCNN\_MultiInput + DenseNet121 tahminlerinin birleştirilmesi.
- Grad-CAM: Modelin odaklandığı bölgelerin görselleştirilmesi.
- Web arayüzü: Flask/FastAPI tabanlı REST API ile klinik test ortamına taşıma.

Bu çalışma Yazılım Mühendisliği dersi kapsamında bir prototip olarak ele alınmalıdır. Klinik kullanım için tıp uzmanlarının onayı ve yasal düzenleyici süreçler zorunludur.

## KAYNAKÇA

- [1] W. W. Greulich ve S. I. Pyle, "*Radiographic Atlas of Skeletal Development of the Hand and Wrist*," 2. Baskı, Stanford University Press, Stanford, CA, 1959.
- [2] S. S. Halabi, L. M. Prevedello, J. Kalpathy-Cramer ve diğerleri, "The RSNA Pediatric Bone Age Machine Learning Challenge," *Radiology*, cilt 290, sayı 2, ss. 498–503, 2019.
- [3] I. Pan, H. H. Thodberg, S. S. Halabi, J. Kalpathy-Cramer ve D. B. Larson, "Improving Automated Pediatric Bone Age Estimation Using Ensembles of Models from the 2017 RSNA Machine Learning Challenge," *Radiology: Artificial Intelligence*, cilt 1, sayı 6, e190053, 2019.
- [4] K. Mader, "RSNA Bone Age Dataset," Kaggle, [Çevrimiçi]. Erişim: <https://www.kaggle.com/datasets/kmader/rsna-bone-age> (Haziran, 2025).
- [5] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov ve L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 4510–4520, 2018.
- [6] M. Tan ve Q. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," *Proceedings of the 36th International Conference on Machine Learning (ICML)*, cilt 97, ss. 6105–6114, 2019.
- [7] G. Huang, Z. Liu, L. Van Der Maaten ve K. Q. Weinberger, "Densely Connected Convolutional Networks," *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 4700–4708, 2017.
- [8] D. B. Larson, M. C. Chen, M. P. Lungren, S. S. Halabi, N. V. Stence ve C. P. Langlotz, "Performance of a Deep-Learning Neural Network Model in Assessing Skeletal Maturity on Pediatric Hand Radiographs," *Radiology*, cilt 287, sayı 1, ss. 313–322, 2018.
- [9] S. Ioffe ve C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, cilt 37, ss. 448–456, 2015.
- [10] D. P. Kingma ve J. Ba, "Adam: A Method for Stochastic Optimization," *International Conference on Learning Representations (ICLR)*, San Diego, CA, 2015.
- [11] M. Abadi ve diğerleri, "TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems," [Çevrimiçi]. Erişim: <https://www.tensorflow.org> (Haziran, 2025).

- [12] Y. LeCun, L. Bottou, Y. Bengio ve P. Haffner, "Gradient-Based Learning Applied to Document Recognition," *Proceedings of the IEEE*, cilt 86, sayı 11, ss. 2278–2324, 1998.
- [13] A. Krizhevsky, I. Sutskever ve G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," *Advances in Neural Information Processing Systems*, cilt 25, ss. 1097–1105, 2012.
- [14] K. He, X. Zhang, S. Ren ve J. Sun, "Deep Residual Learning for Image Recognition," *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 770–778, 2016.
- [15] K. Simonyan ve A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," *International Conference on Learning Representations (ICLR)*, San Diego, CA, 2015.
- [16] S. J. Pan ve Q. Yang, "A Survey on Transfer Learning," *IEEE Transactions on Knowledge and Data Engineering*, cilt 22, sayı 10, ss. 1345–1359, 2010.
- [17] S. H. Tajmir, H. H. Lee, R. Shailam ve diğerleri, "Artificial Intelligence-Assisted Interpretation of Bone Age Radiographs Improves Accuracy and Decreases Variability," *Skeletal Radiology*, cilt 48, ss. 275–283, 2019.
- [18] H. Lee, S. Tajmir, J. Lee ve diğerleri, "Fully Automated Deep Learning System for Bone Age Assessment," *Journal of Digital Imaging*, cilt 30, ss. 427–441, 2017.
- [19] J. M. Tanner, R. H. Whitehouse, N. Cameron, W. A. Marshall, M. J. R. Healy ve H. Goldstein, "Assessment of Skeletal Maturity and Prediction of Adult Height (TW2 Method)," 2. Baskı, Academic Press, Londra, 1975.